Nassim EL HADDAD

TP 3 Deep Learning
CSC 8607 - Deep Learning

Exercice 1 - Préparation d'ImageNet

Les pipelines sont les suivantes :

- **Entraînement :** `RandomResizedCrop(227)` → `RandomHorizontalFlip` → `ToTensor` → `Normalize`
- **Validation :** `Resize(256)` → `CenterCrop(227)` → `ToTensor` → `Normalize`

Pourquoi utiliser `Normalize` ?

Après `ToTensor`, les pixels sont compris entre 0 et 1. La normalisation permet ensuite de les recentrer, ce qui facilite généralement l'apprentissage du modèle. La moyenne et l'écart-type doivent être calculés uniquement sur le jeu d'entraînement. Utiliser aussi la validation pourrait introduire une fuite d'information.

Pourquoi utiliser des augmentations uniquement sur le jeu d'entraînement ?

Le crop aléatoire et le retournement horizontal permettent de varier les images présentées au modèle. Cela augmente la diversité des données et limite le risque qu'il mémorise simplement les images d'entraînement. En validation, on veut au contraire des résultats stables et reproductibles. On utilise donc un prétraitement fixe, avec un redimensionnement puis un crop centré, sans transformations aléatoires.

Dans quels cas le retournement horizontal peut-il être problématique ?

Le retournement horizontal n'est pas toujours pertinent. Dans certains cas, il peut modifier le sens de l'image lorsque la gauche et la droite ont de l'importance pour la classification. C'est le cas pour des caractères comme 6 et 9, b et d, certains panneaux de signalisation ou encore pour distinguer une main gauche d'une main droite.

2. Exercice 2 - MLP vs AlexNet

L'image d'entrée possède 3 canaux et une résolution de 227 × 227 pixels, soit 154 587 valeurs au total. Pour un MLP, elle doit d'abord être aplatie en un seul vecteur avant d'être passée aux couches entièrement connectées.

Tableau des valeur :

Couche	Formule avec biais	Paramètres
Linear1	154 587 × 256 + 256	39 574 528
Linear2	256 × 256 + 256	65 792
Linear3	256 × 1 000 + 1 000	257 000
Total		**39 897 320**

Sans les biais, on obtient 39 895 808 paramètres. La première couche en regroupe donc presque la totalité, avec environ 39,6 millions, soit près de 99 %.

Le principal défaut du MLP est surtout qu'il perd la structure spatiale de l'image en l'aplatissant. Les pixels voisins ne sont plus traités comme tels, et le réseau ne profite pas du partage des poids propre aux convolutions.

Couche	Entrée	Hyperparamètres	Sortie	Param.	KB
Conv1 + ReLU	3, 227×227	64, 11×11, S4, P2	64, 56×56	23 296	784
MaxPool1	64, 56×56	3×3, S2	64, 27×27	0	182
Conv2 + ReLU	64, 27×27	192, 5×5, S1, P2	192, 27×27	307 392	547
MaxPool2	192, 27×27	3×3, S2	192, 13×13	0	127
Conv3 + ReLU	192, 13×13	384, 3×3, S1, P1	384, 13×13	663 936	254
Conv4 + ReLU	384, 13×13	256, 3×3, S1, P1	256, 13×13	884 992	169
Conv5 + ReLU	256, 13×13	256, 3×3, S1, P1	256, 13×13	590 080	169
MaxPool3	256, 13×13	3×3, S2	256, 6×6	0	36
Flatten + Dropout	256, 6×6	p=0,5	9216	0	36
Linear1 + Dropout	9216	4096, p=0,5	4096	37 752 832	16
Linear2 + ReLU	4096	4096	4096	16 781 312	16
Linear3	4096	1000	1000	4 097 000	4

AlexNet conserve la structure spatiale grâce aux couches convolutives, qui utilisent les mêmes filtres à différents endroits de l'image pour détecter des motifs. Il est donc mieux adapté à la classification d'images. AlexNet compte 61 100 840 paramètres, principalement dans les couches entièrement connectées. Les premières couches produisent toutefois de grandes cartes de caractéristiques, ce qui demande davantage de mémoire pour les activations.

Exercice 3 - Entraînement et comparaison (subset 20k)

Pendant l'entraînement, `train()` active le Dropout, tandis que `eval()` le désactive pour passer le modèle en mode évaluation. Il faut donc utiliser `eval()` pendant la validation. Sinon, le Dropout continuerait à désactiver des activations aléatoirement et les résultats seraient moins stables.

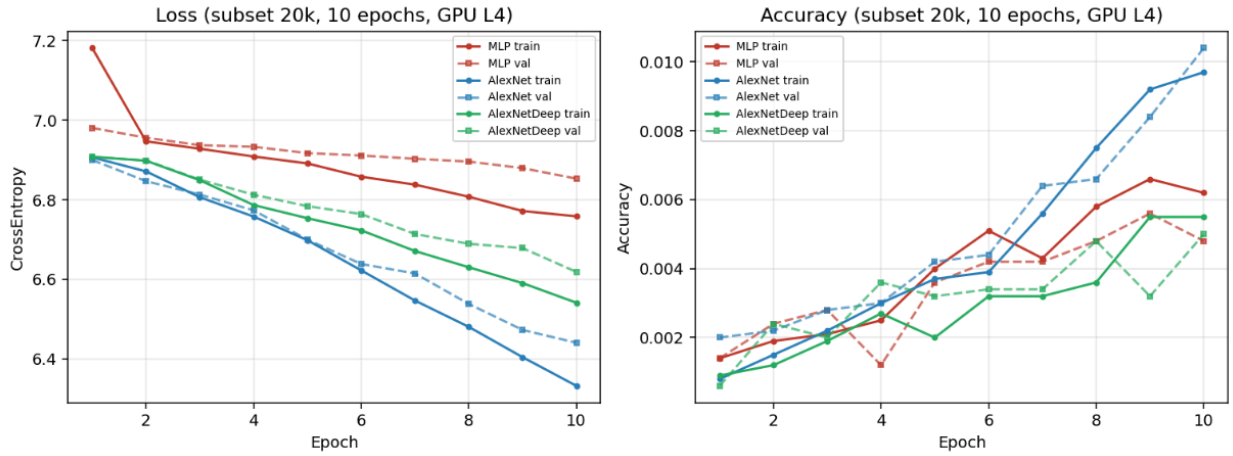
Avec 1000 classes, un modèle initialisé aléatoirement devrait avoir une accuracy proche de 0,1 %. La cross-entropy devrait elle aussi être proche de ln(1000) ≈ 6,9.

Tableau des valeurs :

Modèle	Train Loss	Val Loss	Train Acc	Val Acc
MLP	6.76	6.85	0.006	0.005
AlexNet	6.33	6.44	0.010	0.010
AlexNetDeep	6.54	6.62	0.006	0.005

Après 10 époques, AlexNet est le modèle qui obtient les meilleurs résultats sur le subset de 20 000 images, avec une loss de validation et une accuracy légèrement meilleures que celles du MLP et d'AlexNetDeep. Le MLP reste proche d'un comportement aléatoire. Son architecture exploite mal la structure spatiale des images et doit apprendre directement les relations entre un très grand nombre de pixels. AlexNet s'en sort mieux grâce aux convolutions, qui permettent d'extraire progressivement des caractéristiques visuelles.

AlexNetDeep est moins performant ici, ce qui semble plutôt s'expliquer par un apprentissage encore insuffisant que par de l'overfitting.



Exercice 4 - ImageNet complet (sbatch)

Nombre d'époques : 8.

Une époque dure environ 25 minutes sur GPU L4. À cette vitesse, il faudrait environ 42 heures pour faire 100 époques sans early stopping. On s'arrête ici après 8 époques, ce qui suffit pour analyser le début de l'apprentissage.

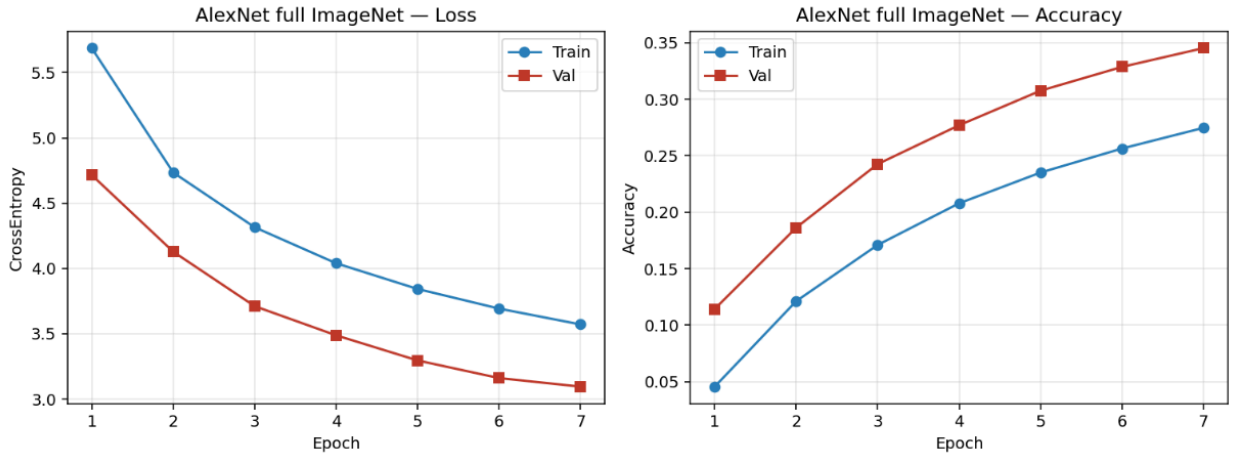
Epoques	Train Loss	Train Acc	Val Loss	Val Acc
1	5.69	0.046	4.72	0.114
2	4.73	0.121	4.13	0.186
3	4.32	0.171	3.71	0.243
4	4.04	0.208	3.49	0.277
5	3.84	0.235	3.30	0.308

6	3.69	0.256	3.16	0.329
7	3.57	0.275	3.09	0.345
8	3.47	0.289	2.98	0.365

Les performances augmentent rapidement au début. À l'époque 8, l'accuracy de validation atteint environ 36,5 %, contre seulement 0,1 % pour une prédiction aléatoire sur 1000 classes. Le modèle a donc déjà appris des caractéristiques utiles pour la classification.

Les résultats sont aussi meilleurs sur ImageNet complet que sur le subset de 20 000 images. Le fait d'avoir davantage de données aide le modèle à mieux généraliser, tandis que les augmentations limitent la mémorisation.

À l'époque 8, l'écart entre le train et la validation reste raisonnable. Il n'y a donc pas encore de signe clair de surapprentissage.



Au début, la loss peut être légèrement plus faible en validation qu'en entraînement, et ce n'est pas forcément inquiétant. Pendant le train, le Dropout est actif et les images sont augmentées, ce qui rend l'apprentissage plus difficile. En validation, ces perturbations sont désactivées, ce qui peut expliquer de meilleurs résultats au début.